

Model Analysis and Explanation


모델 분석과 설명

Model analysis level of abstraction

- 한번에 분석하기 어려우므로 단계별로

1. As a probability distribution and decision function $P_{\text{model}}(y|x)$
2. As a sequence of vector representations in depth and time Layer 2
Layer 1
- ↓
3. Parameter weights, specific mechanisms (attention), dropout, ...

Out-of-domain evaluation sets



In-domain data : Text data from Wikipedia

Out-of-domain data : Except Wikipedia data

↓
task (학습) 아닌
data를 (단순) fitting

NLI (Natural Language Inference)

- 문장 (premise)이 주어진 때 다른 문장 (hypothesis)에 의미적으로 수반?
entail

Entailment, Neutral, Contradiction
같은 의미 무관함 맞지 않음

HANS (강조 dataset)

Influence studies and adversarial examples

Saliency map: model의 prediction에 input이 얼마나 영향 미쳤는지 scoring
⇒ Simple gradient method

Rubbish example

- Beam search, saliency map 반복 적용하여 가장 낮은 점수도 word 삭제

Add any, Add sent

Analyzing representations

Attention map 이용하여 각 layer가 어떤 역할을 하는지 추측

Revisiting model ablations as analysis

Layer를 줄기 vs 알게?

Model accuracy 상승위해 Model tuning

→ 일련의 tuning 과정을

analysis 관점으로 해석 가능